

3.56 msim 二変数間の類似度の計算

`f=`パラメータで指定した項目の二変数間の類似度 (距離) を `c=`パラメータで指定した類似度 (距離) 関数で計算し類似度行列として出力する。

書式

```
msim c= f= [a=] [k=] [n=] [-d] [i=] [o=] [bufcount=] [-assert_diffSize] [-assert_nullkey] [-assert_nnullin] [-assert_nnullout] [-nfn] [-nfno] [-x] [-q] [tmpPath=] [precision=] [--help] [--help1] [--version]
```

パラメータ

- `k=` ここで指定された項目 (複数項目指定可) を単位として求める。
- `f=` ここで指定された項目全ての二項目間の類似度を求める。
- `c=` 類似度 (距離) 名リスト (複数項目指定可)
 次項に示した類似度 (距離) 名を指定する。
 項目名は以下のように, (:) コロンに続けて指定して変更可能。
 コロンに続く名称を省略した場合は類似度 (距離) 関数名がそのまま項目名として利用される。
 例) `msim f=x,y,z c=pearson:`ピアソン積率相関係数,`euclid:`ユークリッド距離,`cosine:`コサイン
 類似度=`covar|ucovar|pearson|spearman|kendall|euclid|cosine|cityblock|hamming|chi|phi|jaccard|supportr|lift|confMax|confMin|yuleQ|yuleY|kappa|oddsRatio|convMax|convMin`
- `a=` 2変数の名称を示す項目名を指定する。カンマで区切って2つ指定する。
 省略すると `f1d1,f1d2` が使われる。
- `-d` 対角行列、上三角行列を出力する。
`-d` オプションが指定されないと類似度行列の下三角行列のみ出力されるが、
`-d` オプションを指定することにより対角行列及び上三角行列も出力される。

類似度 (距離) の定義

実数ベクトル

サイズが同じ2つの実数ベクトル $\mathbf{x} = (x_1, x_2, \dots, x_n)$, $\mathbf{y} = (x_1, x_2, \dots, x_n)$ に関する類似度 (もしくは距離) の定義を表 3.24 に示す。

0-1 ベクトル

値として0もしくは1をとる2つの0-1ベクトル $\mathbf{a} = (a_1, a_2, \dots, a_n)$, $\mathbf{b} = (b_1, b_2, \dots, b_n)$ に関する類似度の定義を表 3.26 に示す。表の中で使われている記号 f_{jk} は、 a_i, b_i がとる値 (0,1) の組み合わせ別の件数で、表 3.25 に示されている。

また $P(\cdot)$ の意味は以下に示すとおりである。

利用例

例 1: 基本例

`x`、`y`、`z` 項目の2項目間の組み合わせについてピアソンの積率相関係数とコサインを計算する。

```
$ more dat1.csv
x,y,z
14,0.17,-14
```

表 3.24 実数ベクトルの類似度一覧

パラメータ値	内容	距離/類似度	定義式	範囲
covar	共分散	類似度	$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$	$-\infty \sim \infty$
ucovar	不偏共分散	類似度	$\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$	$-\infty \sim \infty$
pearson	ピアソンの積率相関係数	類似度	$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}}$	$-1.0 \sim 1.0$
spearman	スピアマンの順位相関係数	類似度	$\mathbf{x}, \mathbf{y}$ を順位に変換しての積率相関係数	$-1.0 \sim 1.0$
kendall	ケンドールの順位相関係数	類似度	$\frac{c-d}{\frac{1}{2}n(n-1)}$ 注 1,2)	$-1.0 \sim 1.0$
euclid	ユークリッド距離 (数値)	距離	$\sqrt{\sum_{i=1}^n (x_i - y_i)^2}$	$0 \sim \infty$
cosine	コサイン	類似度	$\frac{\mathbf{x} \cdot \mathbf{y}}{ \mathbf{x} \mathbf{y} } = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}}$	$-1.0 \sim 1.0$
cityblock	都市ブロック距離	距離	$\sum_{i=1}^n x_i - y_i $	$-\infty \sim \infty$
hamming	ハミング距離	距離	$ \{i \mid x_i \neq y_i, i = 1, 2, \dots, n\} $	$0 \sim n$

注 1) $c = |\{(i, j) \mid (x_i > x_j \text{ and } y_i > y_j) \text{ or } (x_i < x_j \text{ and } y_i < y_j), i > j, i = 1, 2, \dots, n, j = 1, 2, \dots, n\}|$

注 2) $d = |\{(i, j) \mid (x_i > x_j \text{ and } y_i < y_j) \text{ or } (x_i < x_j \text{ and } y_i > y_j), i > j, i = 1, 2, \dots, n, j = 1, 2, \dots, n\}|$

表 3.25 2 変数の値の組み合わせによる 2×2 分割表

	$b_i = 1$	$b_i = 0$	計
$a_i = 1$	f_{11}	f_{10}	$f_{1.}$
$a_i = 0$	f_{01}	f_{00}	$f_{0.}$
計	$f_{.1}$	$f_{.0}$	$f_{..}$

$$P(a) = f_{1.}/f_{..}$$

$$P(b) = f_{.1}/f_{..}$$

$$P(\bar{a}) = f_{0.}/f_{..}$$

$$P(a, b) = f_{11}/f_{..}$$

$$P(a|b) = f_{11}/f_{.1}$$

```
11,0.2,-1
32,0.15,-2
13,0.33,-2
$ msim c=pearson,cosine f=x,y,z i=dat1.csv o=rsl1.csv
#END# kgsim c=pearson,cosine f=x,y,z i=dat1.csv o=rsl1.csv
$ more rsl1.csv
fld1,fld2,pearson,cosine
x,y,-0.5088704666,0.7860308044
x,z,0.1963041929,-0.5338153343
y,z,0.3311001423,-0.5524409416
```

例 2: 対角行列、上三角行列を出力

x、y、z 項目の 2 項目間の組み合わせについてピアソンの積率相関係数とコサインを計算する。(d オプションあり)

```
$ msim c=pearson,cosine f=x,y,z -d i=dat1.csv o=rsl2.csv
#END# kgsim -d c=pearson,cosine f=x,y,z i=dat1.csv o=rsl2.csv
```

表 3.26 0-1 ベクトルの類似度一覧

パラメータ値	内容	距離/類似度	定義式	範囲
chi	カイ 2 乗値	類似度	$\sum_{i=0}^1 \sum_{j=0}^1 \frac{f_{ij} - e_{ij}}{e_{ij}}$ 注 1)	$0 \sim \infty$
phi	ファイ係数	類似度	$\frac{f_{11}f_{00} - f_{10}f_{01}}{\sqrt{f_{1.}f_{0.}f_{.1}f_{.0}}}$	$-1.0 \sim 1.0$
jaccard	ジャックカード係数	類似度	$\frac{P(a,b)}{P(a)+P(b)-P(a,b)}$	$0.0 \sim 1.0$
support	支持度	類似度	$P(a,b)$	$0.0 \sim 1.0$
lift	リフト値	類似度	$\frac{P(a,b)}{P(a)P(b)}$	$0 \sim \infty$
confMax	最大確信度	類似度	$\max(P(a b), P(b a))$	$0.0 \sim 1.0$
confMin	最小確信度	類似度	$\min((P(a b), P(b a))$	$0.0 \sim 1.0$
yuleQ	yule の連関係数 (Q)	類似度	$\frac{\alpha-1}{\alpha+1}$ 注 2)	$-1.0 \sim 1.0$
yuleY	yule の連関係数 (Y)	類似度	$\frac{\sqrt{\alpha}-1}{\sqrt{\alpha}+1}$ 注 2)	$-1.0 \sim 1.0$
kappa	kappa	類似度	$\frac{P(a,b)+P(\bar{a},\bar{b})-P(a)P(b)-P(\bar{a})P(\bar{b})}{1-P(a)P(b)-P(\bar{a})P(\bar{b})}$	$-1.0 \sim 1.0$
oddsRatio	oddsRatio	類似度	$\frac{P(a,b)P(\bar{a},\bar{b})}{P(a,\bar{b})P(\bar{a},b)}$	$0 \sim \infty$
convMax	最大 conviction	類似度	$\max(\frac{P(a)P(\bar{b})}{P(a,\bar{b})}, \frac{P(\bar{a})P(b)}{P(\bar{a},b)})$	$0.5 \sim \infty$
convMin	最小 conviction	類似度	$\min(\frac{P(a)P(\bar{b})}{P(a,\bar{b})}, \frac{P(\bar{a})P(b)}{P(\bar{a},b)})$	$0.5 \sim \infty$

注 1) $e_{ij} = \frac{f_{i.}f_{.j}}{f_{..}}$ 注 2) $\alpha = \frac{f_{11}f_{00}}{f_{10}f_{01}}$

```
$ more rsl2.csv
fld1,fld2,pearson,cosine
x,x,1,1
x,y,-0.5088704666,0.7860308044
x,z,0.1963041929,-0.5338153343
y,x,-0.5088704666,0.7860308044
y,y,1,1
y,z,0.3311001423,-0.5524409416
z,x,0.1963041929,-0.5338153343
z,y,0.3311001423,-0.5524409416
z,z,1,1
```

例 3: キー単位での計算

key 項目を単位にして計算する。

```
$ more dat2.csv
key,x,y,z
A,14,0.17,-14
A,11,0.2,-1
A,32,0.15,-2
B,13,0.33,-2
B,10,0.8,-5
B,15,0.45,-9
$ msim k=key c=pearson,cosine f=x,y,z i=dat2.csv o=rsl3.csv
```

```
#END# kgsim c=pearson,cosine f=x,y,z i=dat2.csv k=key o=rsl3.csv
$ more rsl3.csv
key%0,fld1,fld2,pearson,cosine
A,x,y,-0.8746392857,0.8472573627
A,x,z,0.3164384831,-0.521983618
A,y,z,0.1830936883,-0.6719258683
B,x,y,-0.7919009884,0.8782575583
B,x,z,-0.471446429,-0.9051543403
B,y,z,-0.1651896746,-0.8514129252
```

例 4: 類似度名の指定

01 値のデータに付いての計算。ハミング距離と phi 係数を計算する。

```
$ more dat3.csv
x,y,z
1,1,0
1,0,1
1,0,1
0,1,1
$ msim c=hamming,phi f=x,y,z i=dat3.csv o=rsl4.csv
#END# kgsim c=hamming,phi f=x,y,z i=dat3.csv o=rsl4.csv
$ more rsl4.csv
fld1,fld2,hamming,phi
x,y,0.75,-0.5773502692
x,z,0.5,-0.3333333333
y,z,0.75,-0.5773502692
```

例 5: 類似度名の変更

01 値のデータに付いての計算。ハミング距離と phi 係数を計算し、出力項目名を変更する。

```
$ msim c=hamming:ハミング距離,phi:ファイ係数 a=変数 1, 変数 2 f=x,y,z i=dat3.csv o=rsl5.csv
#END# kgsim a=変数 1, 変数 2 c=hamming:ハミング距離,phi:ファイ係数 f=x,y,z i=dat3.csv o=rsl5.csv
$ more rsl5.csv
変数 1, 変数 2, ハミング距離, ファイ係数
x,y,0.75,-0.5773502692
x,z,0.5,-0.3333333333
y,z,0.75,-0.5773502692
```

関連コマンド

mstats : 1 変量の統計量を計算するときはこちら。

mmvsim : 移動窓を設定した類似度計算。