

3.10 mchksv CSV データのチェック

MCMD が前提とする CSV の仕様を満たしていないデータを自動修復する (項目数の統一など)。また、`-diag` オプションを指定することで、CSV データのチェックのみ実行する。

書式

```
mchksv [a=] [-diag] [-r] [i=] [o=] [-assert_nullout] [-nfn] [-nfno] [-x] [-q] [tmpPath=] [--help] [--help1]
[--version]
```

パラメータ

- i=** 入力ファイル名
このパラメータで指定した CSV データに不備な箇所がないかチェックを行い、
不備がある場合その箇所を自動的に補完する。
このパラメータが省略された時には標準入力を用いられる。
- a=** 入力データの項目名を無視し、ここで指定した項目名を出力する。
ここで指定した項目数が入力データの項目数より少ない場合は、
入力データの左から順番に指定の個数分の項目が出力される。
逆に、ここで指定した項目数が入力データの項目数より多い場合、不足分は NULL 値が出力される。
- diag** チェックのみ実行する。
このオプションを指定した場合、結果は標準出力に出力される。
- r** 制御文字を無視
ここでは ASCII 文字コードの 0x00~0x1f,0x7f(0x09,0x0a,0x0d は除く) を制御文字と定義している。
このオプションを指定しなければ制御コードは自動的に `&#x` という文字列に変換される。

利用例

例 1: データの補完

データの項目数が違う (2,4 行目が 3 項目しかない) 問題のあるデータを M コマンドで利用できるデータに補完 (4 項目に自動的に補完) する。

```
$ more dat1.csv
商品, 日付, 数量, 金額
A,20081201,1,10
A,20081202,2,
A,*,3
B,20081201,4,40
B,20081203,50
$ mchksv i=dat1.csv o=rsl1.csv
#END# kgchksv i=dat1.csv o=rsl1.csv
$ more rsl1.csv
商品, 日付, 数量, 金額
A,20081201,1,10
A,20081202,2,
A,*,3,
B,20081201,4,40
B,20081203,50,
```

例 2: データの補完、項目名変更

データの項目数が違う (3,5 行目が 3 項目しかない) 問題のあるデータを M コマンドで利用できるデータに補完 (4 項目に自動的に補完) する。その際に、入力データの左の項目から順番に「商品, 日付, 数量, 金額」という項目名で出力する。

```
$ more dat2.csv
fld1,fld2,fld3,fld4
A,20081201,1,10
A,20081202,2,
A,*,3
B,20081201,4,40
B,20081203,50
$ mchkcsv a=商品, 日付, 数量, 金額 i=dat2.csv o=rsl2.csv
#END# kgchkcsv a=商品, 日付, 数量, 金額 i=dat2.csv o=rsl2.csv
$ more rsl2.csv
商品, 日付, 数量, 金額
A,20081201,1,10
A,20081202,2,
A,*,3,
B,20081201,4,40
B,20081203,50,
```

例 3: データの不備チェック、診断結果の出力

CSV データに不備な箇所がないかチェックのみを行い、CSV ファイル診断結果を出力する。

```
$ mchkcsv -diag i=dat1.csv o=rsl3.csv
#END# kgchkcsv -diag i=dat1.csv o=rsl3.csv
$ more rsl3.csv
#=====
# CSV ファイル診断
# file name : dat1.csv
#-----
# 結果の一文字目の意味
# # : 情報行 (問題なし)
# ? : KGMOD にて扱えない問題点 (?の後の文字は解説参照)
# よって、左端が全て#になれば OK
#=====
##### ヘッダー情報 (1 行目) ###
# 項目数 : 4
# 項目 No. 項目名
# 1 商品
# 2 日付
# 3 数量
# 4 金額
#
##### EOL(End Of Line) 情報 (ヘッダー含む) ##
# LF 改行行数 : 6 (LineNo: 0 1 2 ... )
#
##### データ行情報 (ヘッダー含まない) ###
# 総行数 : 5
# 総バイト数 : 66
# 平均長 : 13.2
# 最大長 : 16 (LineNo:2)
# 最小長 : 6 (LineNo:4)
# 注:長さは、改行文字も含めた長さ
#
##### 項目数の一貫性 ###
?g 異なる項目数の行が発見されました。
?g 項目数:3 (LineNo:4)
```

```
?g 項目数:3 (LineNo:6)
#
##### 項目情報 ###
# 項目番号 [1] 項目名 [商品]
#   NULL 値の行数           : 0
#   DQUOTE で囲われていない行数 : 5 (LineNo: 1 2 3 ... )
#   DQUOTE で囲われている行数   : 0
#
# 項目番号 [2] 項目名 [日付]
#   NULL 値の行数           : 0
#   DQUOTE で囲われていない行数 : 5 (LineNo: 1 2 3 ... )
#   DQUOTE で囲われている行数   : 0
#
# 項目番号 [3] 項目名 [数量]
#   NULL 値の行数           : 0
#   DQUOTE で囲われていない行数 : 5 (LineNo: 1 2 3 ... )
#   DQUOTE で囲われている行数   : 0
#
# 項目番号 [4] 項目名 [金額]
#   NULL 値の行数           : 1 (LineNo: 2 )
#   DQUOTE で囲われていない行数 : 3 (LineNo: 1 2 4 )
#   DQUOTE で囲われている行数   : 0
#
##### 問題点の解説 ###
# ?a : 同じ項目名があると項目番号を特定できない。
#   【対処方法】 kgchkcscv a=x,y,z のように項目名を新たに指定する。
# ?b : 項目名に不正な文字があるとエラーになる
#   【対処方法】 kgchkcscv a=x,y,z のように項目名を新たに指定する。
# ?c : KGMOD が扱う改行は高速化のため LF (UNIX 改行) のみ。
#   この問題は RFC4180 には準拠しておらず KGMOD 独自の制約である。
#   【対処方法】 kgchkcscv にて全て LF に変換される。
#
# ?d : 最終行に LF や CR などの改行 (EOL) 文字が存在しない。
#   これは RFC4180 にも準拠していない。
#   【対処方法】 kgchkcscv にて LF が付加される。
#
# ?e : データファイル内に '\0' が入り込んでいる。
#   テキストファイルでない可能性が高い。
#   RFC4180 には準拠していない。
#   【対処方法】 kgchkcscv にて、"&#x00
#               kgchkcscv -r にて \0 は削除される。
#
# ?f : KGMOD が扱える一行の最大長を超過している。
#   現在の設定では 1024000 バイト以上の長さの行は扱えない。
#   【対処方法】 環境変数を設定することで最大値を変更可能である。
#               ex) export KG_MaxRecLen=204800
#               ただし 10240000 バイトを越えては指定できない。
#               この問題は RFC4180 には準拠しており KGMOD 独自の制約である。
#
# ?g : KGMOD では全行同じ項目数を前提とする。
#   この問題は RFC4180 には準拠しており KGMOD 独自の制約である。
#   【対処方法】
#       1) kgchkcscv データ HEADER の項目数に合わせる。
#          超過項目は捨てられ、足りない項目は null 値となる
#       2) kgchkcscv a=x,y,z HEADER 行をスキップし、
#          指定した x,y,z を項目名として 1) と同様の処理を行う。
#
# ?h : 制御文字 (0x01~0x1F, 0x7F) が項目値として入り込んでいる。
#   テキストファイルでない可能性が高い。
#   RFC4180 には準拠していない。
#   【対処方法】 kgchkcscv にて、"&#x01
#               kgchkcscv -r にて制御文字は削除される。
#
# ?i : TAB は利用できない。
```

```
# RFC4180 には準拠していない。
# 【対処方法】 kgchksv にて、"&#x09
# kgchkcsv -r にて TAB は削除される。
#
# ?j : DQUOTE で囲われていない中で DQUOTE が見つかった
# ex) NG: xxx,oo"oo,xxx -> OK: xxx,"oo""oo",xxx
# RFC4180 には準拠していない。
# 【対処方法】 kgchkcsv にて上記の変換を行う。
#
# ?k : DQUOTE で囲われている中で単一の DQUOTE が見つかった
# ex) NG: xxx,"oo"oo",xxx -> OK: xxx,"oo""oo",xxx
# RFC4180 には準拠していない。
# 【対処方法】 kgchkcsv にて上記の変換を行う。
#-----
```

関連コマンド